UM6P Bioinformatics Lab College of Computing

Classificateur de fonction de protéines

IA et Biologie : de la compréhension de l'ADN à la distillation de modèles

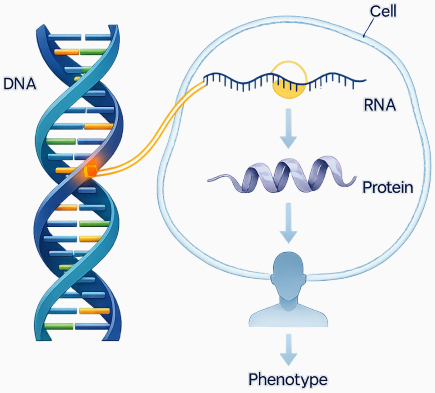
ATELIER bioIA AfricaBP · 28 – 29 OCTOBRE 2026

Le problème

De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

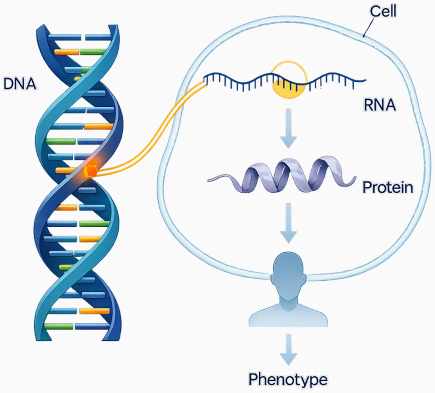
- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C



De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

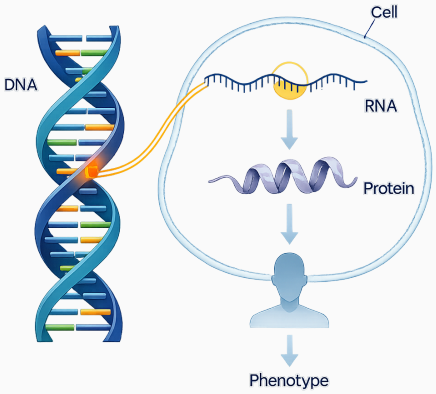
- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN



De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

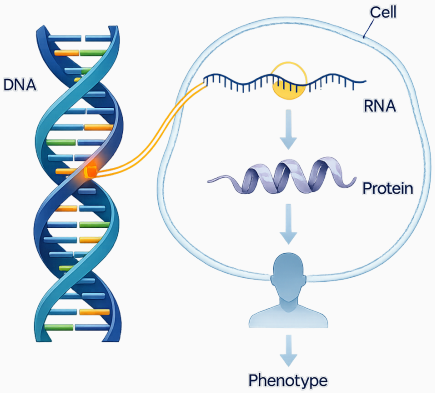
- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN
- **La traduction** lit cet ARN *trois lettres à la fois*, chaque triplet (codon) désigne un acide aminé, et la chaîne d'acides aminés forme une **protéine**



De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN
- **La traduction** lit cet ARN *trois lettres à la fois*, chaque triplet (codon) désigne un acide aminé, et la chaîne d'acides aminés forme une **protéine**



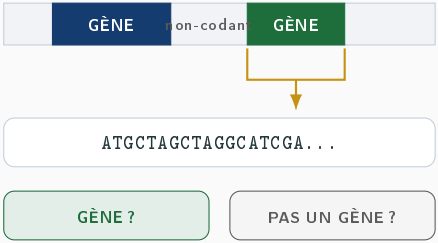
Ce qu'il faut retenir

Seules certaines portions de l'ADN suivent ce chemin jusqu'à la protéine : ces portions particulières, ce sont les **gènes**.

Où sont les gènes ?

- ~~Humain~~ ~~Plante~~ **Bactérie**

  nous travaillons avec des **bactéries** : des génomes petits et bien annotés
- Leur génome, c'est **des millions de lettres** à la suite : [3pt] `...ATGCTAGCTAGGCCGGCATG ...`
- **Rien ne les sépare visuellement.** Pas de titres, pas d'espaces.



La question de l'atelier

Notre tâche : **prédire où se trouvent les gènes**. On vous donne 200 lettres d'ADN — est-ce un morceau de gène, oui ou non ?

Ce n'est pas un exercice d'école

Chaque fois qu'un nouvel organisme est séquencé — une bactérie résistante aux antibiotiques, un virus, un microbe du sol — **quelqu'un doit trouver ses gènes**. C'est la première étape de toute la biologie moderne.

Et personne ne le fait à la main.

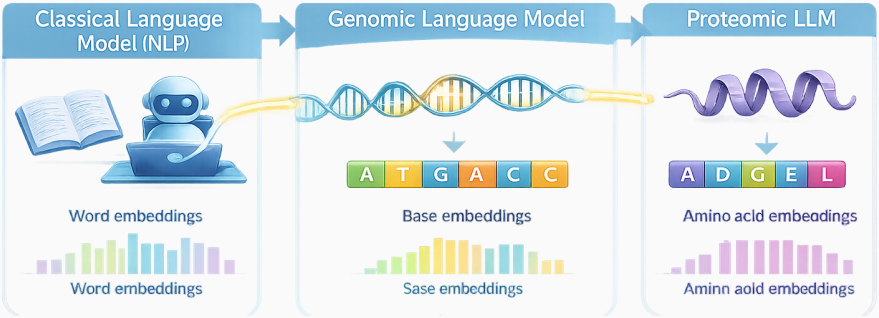
Un problème de « trouver l'aiguille »

Des millions de fenêtres possibles, deux réponses possibles. C'est exactement le type de tâche où l'IA est bonne… si on lui donne la bonne représentation des données.

4	∼4 M	2
LETTRES	PAR GÉNOME	RÉPONSES

L'idée forte

L'opportunité : la biologie a ses propres modèles de langage



Langage naturel

Prédire le mot suivant

GPT : apprend la grammaire, la syntaxe et le sens

Séquences biologiques

Prédire le nucléotide suivant

DNABERT, Evo2... : apprennent la structure et la fonction biologiques

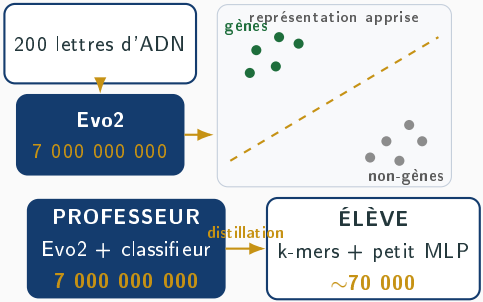
Evo2 : une représentation riche… mais un modèle énorme

L'idée : on demande à **Evo2** une représentation riche des ADN & on branche ensuite un petit classifieur dessus

Le problème : 7 milliards de paramètres. Impossible à faire tourner sur un laptop ou un séquenceur de terrain.

La solution : la distillation

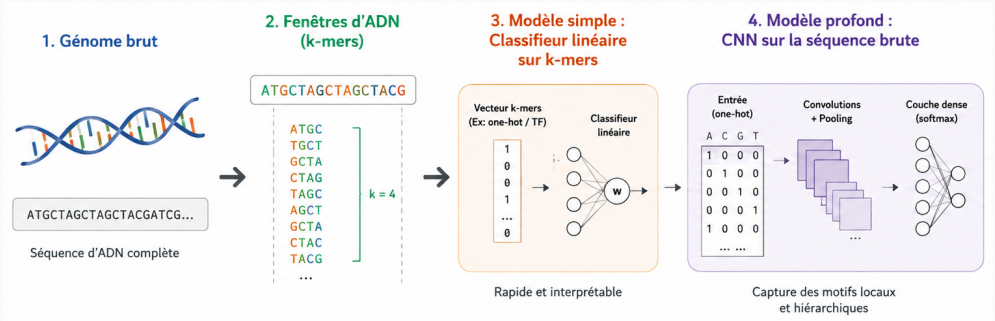
Le gros modèle « professeur » entraîne un modèle « élève » minuscule, en lui transmettant non pas la bonne réponse, mais son degré d'hésitation.



Ce que nous construirons

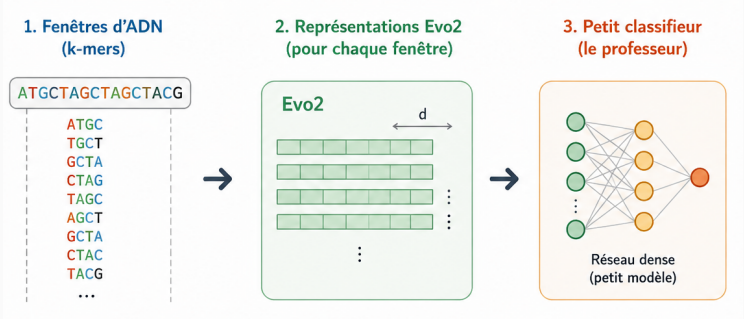
Trois jours, cinq labs + un bonus : un pipeline complet

LAB 1 — Données + baselines → **LAB 2** — Evo2 : le professeur → **LAB 3** — Distillation prof → élève → **LAB 4** — Le verdict : taille vs précision → **LAB 5** — Qu'a compris le modèle, seul ? → **LAB BONUS** — Et les protéines ? mini-démo ESM2



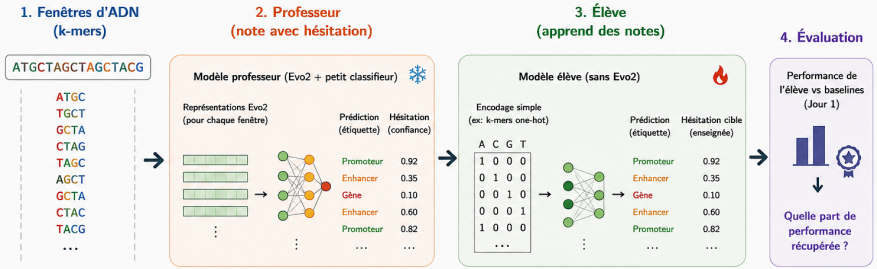
Trois jours, cinq labs + un bonus : un pipeline complet

LAB 1 — Données + baselines → **LAB 2** — Evo2 : le professeur → **LAB 3** — Distillation prof → élève → **LAB 4** — Le verdict : taille vs précision → **LAB 5** — Qu'a compris le modèle, seul ? → **LAB BONUS** — Et les protéines ? mini-démo ESM2



Trois jours, cinq labs + un bonus : un pipeline complet

LAB 1 Données + baselines → **LAB 2** Evo2 : le professeur → **LAB 3** Distillation prof → élève → **LAB 4** Le verdict : taille vs précision → **LAB 5** Qu'a compris le modèle, seul ? → **LAB BONUS** Et les protéines ? mini-démo ESM2



Trois jours, cinq labs + un bonus : un pipeline complet

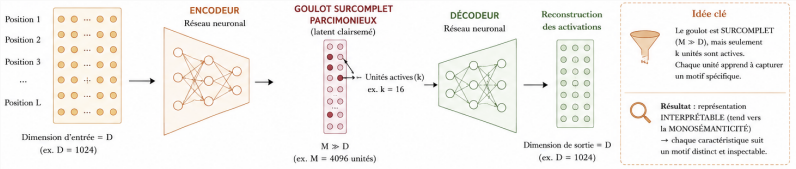


- Tous les modèles sur un seul graphique : précision, taille, latence
- **Que garderiez-vous** pour un appareil de terrain ?

Trois jours, cinq labs + un bonus : un pipeline complet



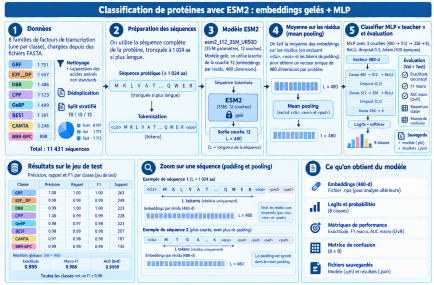
- Sans aucune étiquette, que le modèle a-t-il découvert tout seul ?
- Autoencodeurs parcimonieux sur les activations d'Evo2



Trois jours, cinq labs + un bonus : un pipeline complet



- Le même pipeline, appliqué aux **protéines**
- ESM2 (modèle de langage protéique) → embeddings → petit classifieur
- 8 familles de facteurs de transcription végétaux
- Une courte démo, **optionnelle**



COMMENT ON TRAVAILLE

Vous complétez les trous, lab après lab.

Chaque matin, un notebook **incomplet** vous attend : le squelette est là, les morceaux qui comptent sont à vous. Vous codez, nous passons si besoin, et le soir votre pipeline a avancé d'un cran.

En trois jours, vous serez passés d'un génome brut à un modèle compressé que vous aurez construit, mesuré et compris.